PROYECTO FINAL / PROGRAMACIÓN COMERCIAL

Saldo

Finanzas personales asistidas por IA

Propuesta, arquitectura, modelo de datos y evidencias de implementación.

Objetivo y destinatarios

Ayudar a estudiantes y personas que registran manualmente sus finanzas a comparar presupuesto y ejecución, consultar sus registros con fuentes y explorar metas de ahorro mediante escenarios explicables.

El usuario administra sus propios registros e historial. El administrador gestiona usuarios, corpus, configuración de IA y cuotas. Una cuenta BI independiente solo consulta reportes.

Decisión de alcance	Implementación
Núcleo del producto	GTQ; categorías, obligaciones, pagos parciales, recurrentes mensuales y metas con aportes/retiros.
IA obligatoria	RAG sobre PostgreSQL + agente de presupuesto + agente de metas con herramientas y fuentes externas.
Reporterías	Consultas y tokens por usuario, fecha y servicio; misma API para web y Power BI.
Exclusiones aprobadas	Tarjetas, FIFO, amortización contractual, multidivisa operativa, banca real y fondos compartidos. Las deudas sí pueden registrarse manualmente.
Presupuesto	USD 0; capas Free, sin tarjetas ni activaciones de pago.

Estado de esta revisión

Publicación acreditada del commit bb4dc32. Pruebas backend: 417. Power BI verificado; el archivo PBIX forma parte de esta entrega.

Cierre de los criterios del enunciado sobre el prototipo y los casos comprobados. El asesor tiene límites explícitos; la copia del escenario financiero ampliado de Ana a Neon sigue pendiente de confirmación y no se presenta como realizada.

Corte del informe: 2026-11-08. Fecha de entrega indicada en la consigna: 10 de noviembre. Los registros de demostración son ficticios.

Aplicación: https://saldo-academico.onrender.com
Repositorio: https://github.com/mariofrodm/saldo-academico

02 Arquitectura y stack

Un solo contenedor publica React y FastAPI en HTTPS. PostgreSQL conserva el estado; Render no requiere disco persistente.

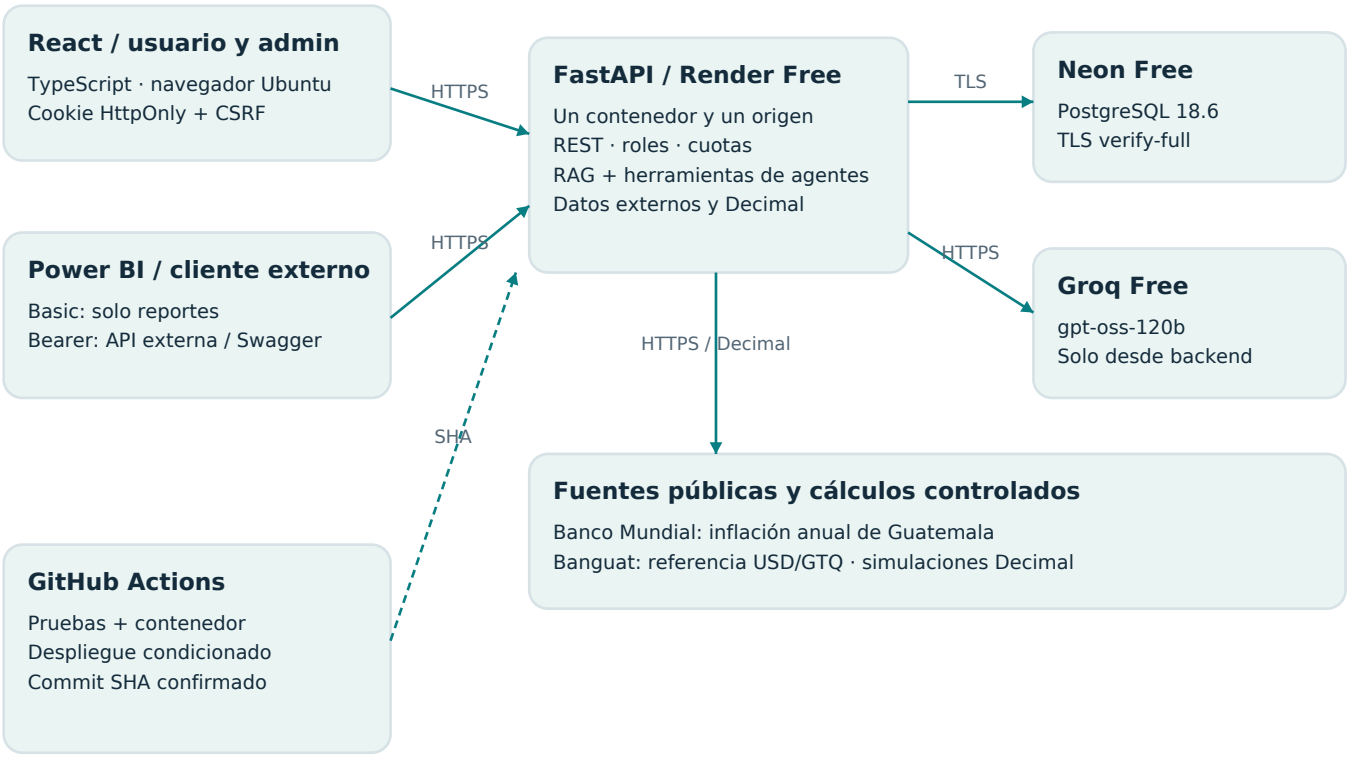


Figura 1. Recorrido real desde GUI, cliente externo y Power BI. Las claves de Groq y Neon permanecen en el servidor.

Componente	Tecnología y responsabilidad
Interfaz	React 19.3.1, TypeScript 7.0.2 y Vite 8.3.5; compilación estática.
API	Python 3.12, FastAPI 0.162.0, Pydantic, Uvicorn y psycopg 3.3.6; SQL parametrizado.
Persistencia	PostgreSQL 18.6 en Neon Free; PostgreSQL 17 en local/CI; migraciones Alembic.
Inferencia	Groq Free, openai/gpt-oss-120b; herramientas autorizadas y límites por ronda.
Publicación	Docker multietapa, usuario sin privilegios; Render Free 512 MB; GitHub Actions.
Analítica	Power BI web con importación HTTPS Basic; PBIX exportable y ruta Desktop si fuese necesaria.

Fabric no es una dependencia del backend. El RAG usa recuperación textual nativa de PostgreSQL; no requiere servicio vectorial ni embeddings de pago.

03 Servicios de IA y fuentes

El modelo decide herramientas y continúa con sus resultados. Los cálculos monetarios y las consultas autorizadas los ejecuta el backend.

RAG · respuesta sobre información recuperada

La pregunta recupera corpus activo mediante búsqueda textual española de PostgreSQL y movimientos propios relevantes. Las guías Markdown se fragmentan e indexan explícitamente; no hay embeddings ni entrenamiento propio. Se conservan hasta seis intercambios completos y referencias verificadas, dentro de un presupuesto acotado. El chat responde en lenguaje natural; fuentes y herramientas se revisan en Historial. Cuando falta información debe reconocerla.

Ejemplo de cálculo: una obligación de Q900 con un abono de Q400 deja Q500 pendientes. La base conserva obligación y pago por separado; el acceso a movimientos ajenos se excluye antes de construir el contexto. La documentación educativa es contexto, no una autorización de acceso.

Agente presupuesto · combinación de información

budget_external_review reúne flujo propio e inflación anual de Guatemala (FP.CPI.TOTL.ZG, Banco Mundial). El modelo elige sus argumentos y el backend ejecuta pasos de lectura y consulta externa; una segunda inferencia explica. El período financiero y el año externo se validan por separado. Si el dato no está publicado se informa; no se inventa inflación mensual.

Agente metas · consulta y simulaciones

goal_external_scenarios consulta la meta propia elegida, calcula dos escenarios con Decimal y obtiene Banguat si se pidió. El modelo selecciona la herramienta y los argumentos; el backend realiza esos pasos secuenciales y la segunda inferencia explica. No modifica saldos ni promete asequibilidad. La referencia cambiaria no es una tasa bancaria garantizada.

Fuente	Dato y tratamiento
PostgreSQL / corpus	Registros propios y guía educativa administrada; fuentes y resultados recuperables desde Historial.
Banco Mundial	Inflación anual de Guatemala, con año, disponibilidad y procedencia. No convertirla a inflación mensual ni usarla como predicción.
Banguat	Referencia diaria USD/GTQ con fecha devuelta por la fuente. No es una tasa garantizada de liquidación bancaria.

Control de ejecución

Herramientas de lectura en lista permitida por servicio, argumentos validados, tiempos máximos y hasta seis rondas. El recorrido general carga la guía 00 versionada. Los dos recorridos externos usan external_system específico y compacto, con referencias verificadas y hechos recién consultados, sin enviar la guía completa ni prosa vieja. Los esquemas se seleccionan según la petición. Algunas consultas sencillas usan respuestas calculadas sin Groq. La memoria y los detalles opcionales se compactan preservando pregunta, fechas, reglas y totales. Un límite sin resultado final queda registrado; no se inventa una respuesta de proveedor.

El contenido generado puede variar entre ejecuciones. Las fuentes y resultados de herramientas quedan persistidos para revisar sus afirmaciones; una respuesta natural no equivale por sí sola a una validación factual.

04 Modelo de datos · dominio

Esquema relacional real. Se muestran claves y atributos principales; backend/schema.sql contiene todas las columnas, restricciones e índices.

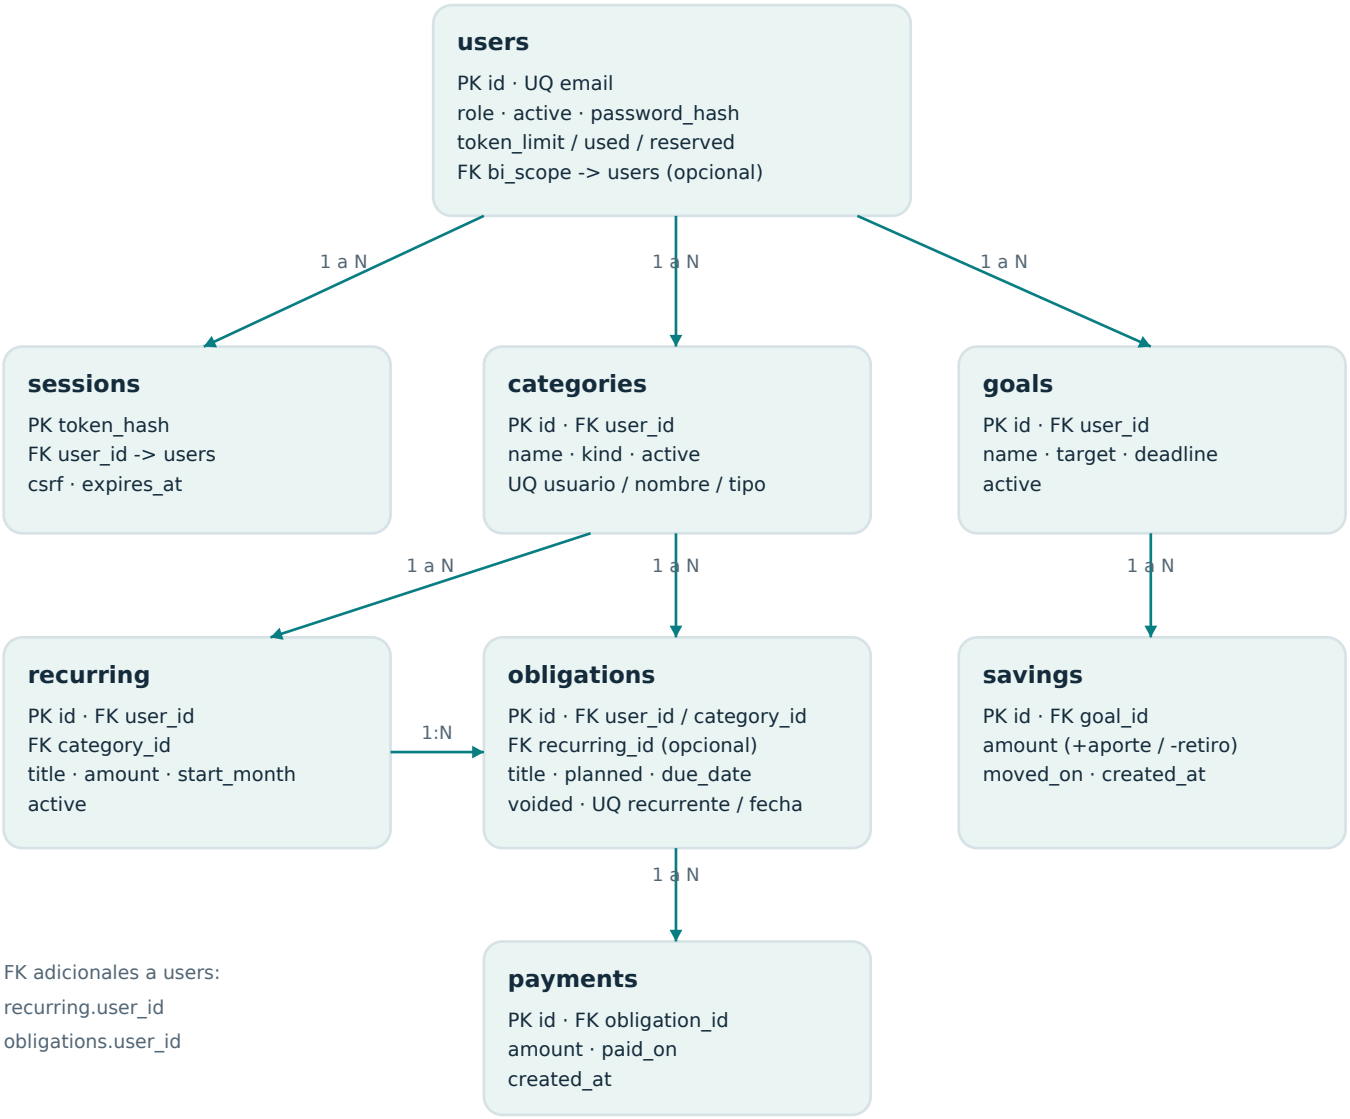
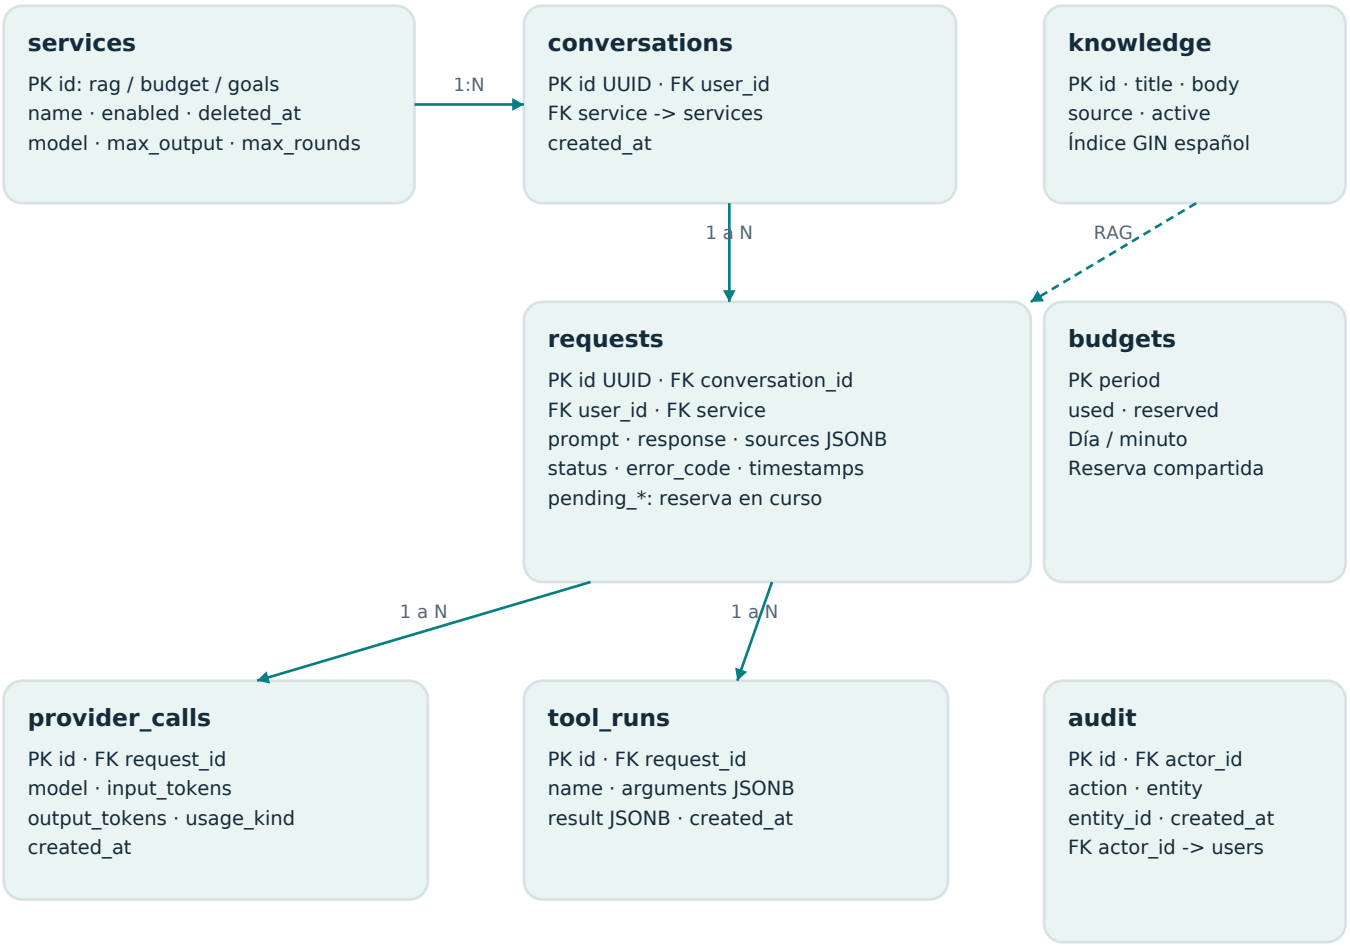


Figura 2. Ocho tablas de identidad y finanzas. PK: clave primaria; FK: clave foránea; UQ: unicidad. Las flechas indican la relación de padre a hijo.

Regla	Implementación
Exactitud monetaria	NUMERIC(15,2), Decimal y redondeo HALF_UP. Importes JSON como cadenas decimales.
Pagos e historial	Pagos separados de obligaciones. Se preservan monto y fecha; anulación/inactivación para registros con historial. El borrado de meta y sus movimientos es explícito, transaccional y auditado.
Recurrentes	UNIQUE(recurring_id,due_date) evita duplicar instancias; generación al solicitar el tablero, sin cron de pago.
Ahorro	Saldo = suma de movimientos. Los aportes reducen disponible y aumentan ahorro; no se presentan como consumo.

05 Modelo de datos · IA y auditoría

Las ocho tablas siguientes completan las 16 tablas del sistema. Conversaciones, rondas de proveedor y herramientas tienen granularidades distintas.



FK a users: conversations.user_id, requests.user_id y audit.actor_id.

requests.service también referencia services.id. knowledge y budgets no tienen FK.

Línea discontinua: recuperación lógica; no es una llave foránea.

Figura 3. Relaciones de IA, historial y control. Se conservan solicitudes fallidas y consumo desconocido estimado; no se elimina el historial para mejorar indicadores.

Entidad	Por qué existe
requests	Una pregunta del usuario: texto, respuesta, estado, fuentes y reserva pendiente.
provider_calls	Una ronda de inferencia: tokens de entrada/salida y origen del cómputo. Varias rondas pueden pertenecer a una solicitud.
tool_runs	Argumentos y resultado intermedio de cada herramienta, ligados a la pregunta.
budgets / audit	Reserva compartida por día/minuto y trazabilidad de cambios administrativos.

06 Acceso, cuotas y verificación

Los permisos se aplican en el backend y se prueban con accesos cruzados; ocultar una opción del menú no es el control de seguridad.

Acceso	Control aplicado
Usuario	Solo entidades, conversaciones y consumo propios; comprobación de propiedad también en herramientas.
Administrador	CRUD de usuarios/corpus y configuraciones de los tres servicios; baja lógica de cuentas/servicios, historial conservado y filtros globales por usuario, fecha y servicio.
Web y API externa	Contraseñas scrypt con sal; sesiones almacenadas como hash. Cookie HttpOnly, Secure en producción, SameSite Strict y CSRF; Bearer para clientes externos.
Power BI	Cuenta bi independiente; Basic solo sobre HTTPS y endpoints de lectura. Sin acceso a IA ni cambios del dominio.

Consumo verificable antes y después de la llamada

Cada ronda reserva de forma atómica cuota personal y compartida antes de contactar Groq. Después concilia los tokens informados. Un rechazo 4xx libera la reserva; si el uso no se confirma por un corte de conexión, se conserva una estimación conservadora y se etiqueta como tal.

Al arrancar se concilian reservas interrumpidas antiguas una sola vez. El límite configurado no constituye una promesa de disponibilidad de Groq: también aplican las cuotas del proveedor y las del proyecto.

Verificación automatizada	Cobertura significativa
Identidad y dominio	Login/CSRF, roles, propiedad, pagos parciales, arrastre sin duplicados, recurrentes y ahorro sin sobregiro.
RAG y agentes	Fuentes y memoria, insuficiencia, varias herramientas/rondas, conversaciones ajenas y límite de pasos.
Cuotas y errores	Reservas concurrentes, reversión compartida, 429, timeout, usage ausente y recuperación idempotente.
Reporte y API	Cursor, fecha Guatemala, snapshot as_of, Basic de lectura, health y OpenAPI.

Pruebas backend acreditadas por este manifest: 417. La suite usa PostgreSQL 17 aislado y simula Groq/fuentes públicas: no consume tokens. La aceptación real se documenta por separado en el entorno publicado.

Comprobaciones adicionales del manifest: subpruebas backend: 106, frontend: 14, aceptación API: 63.

Alcance de la evidencia: no se realizó una auditoría de seguridad ni una prueba de carga masiva. La suite muestra el comportamiento esperado de los casos cubiertos.

07 Despliegue y costo cero

La publicación usa los planes gratuitos existentes. No se agregaron tarjetas, discos ni servicios de pago.

Pruebas → contenedor → despliegue por SHA

El workflow ejecuta backend y construcción/arranque del contenedor en jobs separados. Deploy requiere éxito de ambos, push a main y habilitación explícita. Render tiene auto-deploy apagado; GitHub solicita el commit exacto mediante ref=SHA y espera disponibilidad con ese mismo SHA y base accesible.

Commit de implementación: bb4dc3293d90307dc6afce6be729e022b40fb0f8. Estado de publicación: verificado.

Ejecución CI/CD completa en GitHub Actions

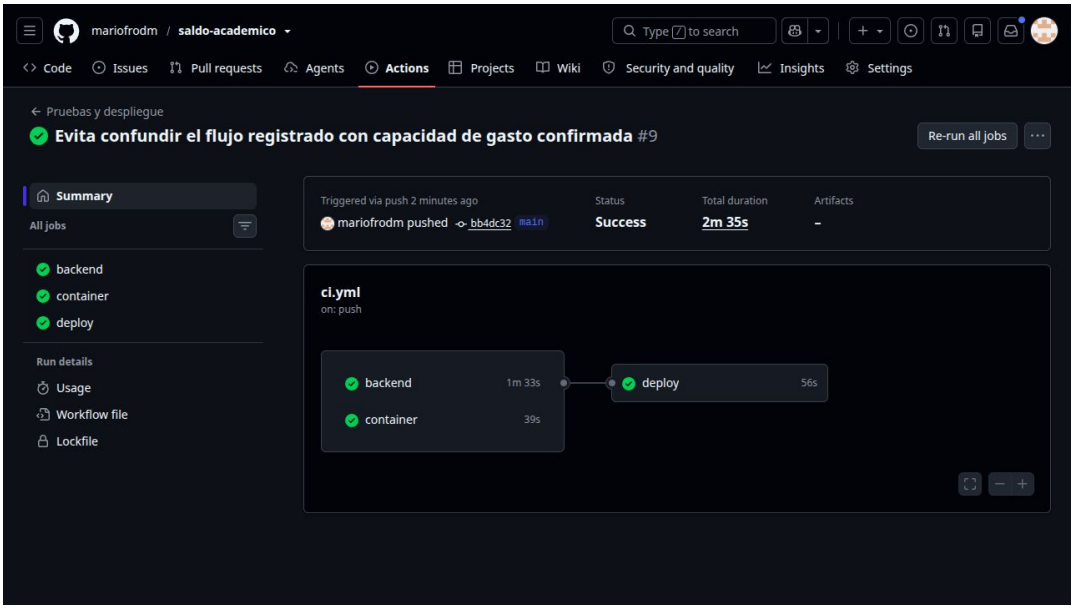


Figura 4. CI/CD exitoso de la implementación bb4dc32: backend, contenedor y despliegue condicionados.

Servicio / plan	Condición de operación
Render Free	Contenedor 512 MB. Puede dormir tras inactividad; abrir antes de la demostración. No usar pings artificiales para evitar la suspensión.
Neon Free	Persistencia PostgreSQL y suspensión por inactividad; cuota finita. TLS verify-full en conexión directa y agrupada.
Groq Free	Cuotas por minuto/día y clave con vencimiento 02/12/2026. No habilitar planes facturables al alcanzar límites.
GitHub / Power BI	Repositorio público y Actions para el proyecto. Cuenta institucional para Power BI; revisar vencimiento y conservar PBIX exportado.

La infraestructura Free puede cambiar o suspenderse; el proyecto no depende de comprar una ampliación. Si una cuota se agota, se reduce el uso o se espera su reinicio. Las credenciales quedan fuera de Git y del PDF.

08 Aplicación publicada y API

La evidencia corresponde al entorno declarado en el manifest; no se reutilizan capturas locales como publicación.

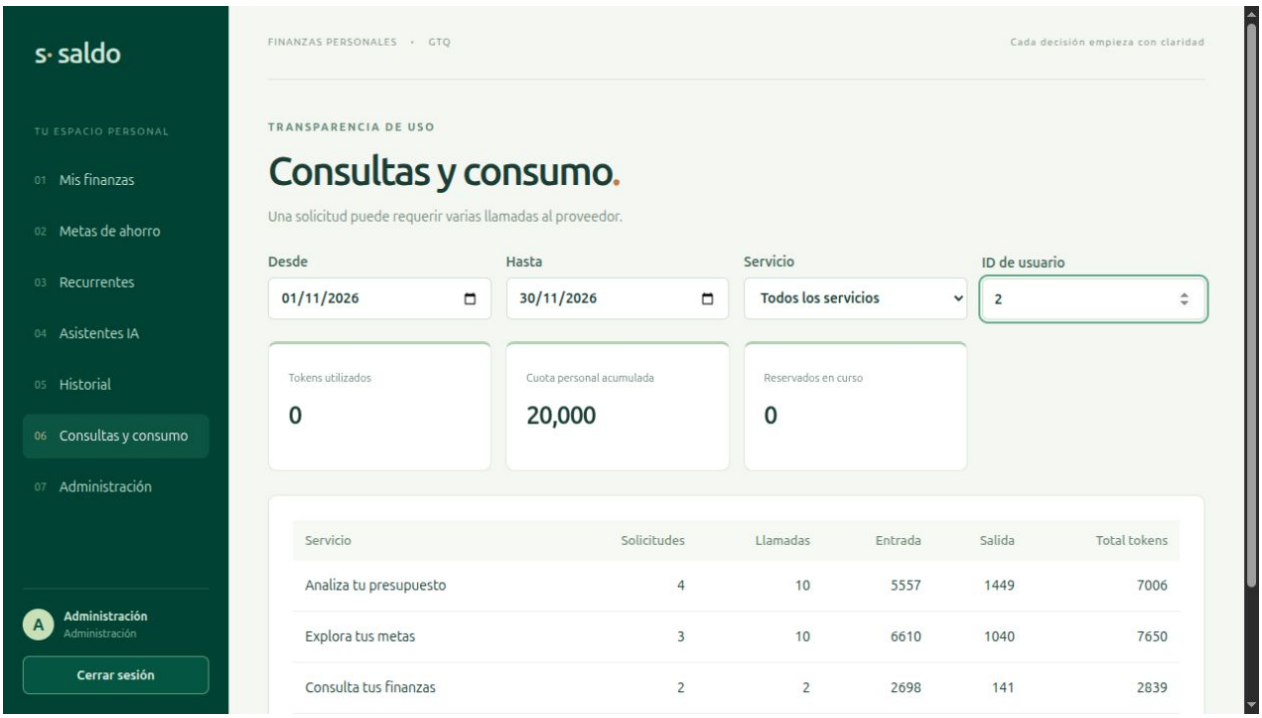


Figura 5. GUI publicada: reporte web cloud para usuario 2, noviembre de 2026. Sus filas coinciden con la API y Power BI; las tarjetas superiores son la cuota personal del administrador autenticado.

Consulta y consumo: mismas reglas en web y Power BI

GET /api/v1/reports/usage entrega una fila por solicitud y agrega todas sus llamadas. GET /api/v1/reports/summary resume por servicio. Filtros de fecha en America/Guatemala, usuario según permisos y servicio. Un único as_of congela el corte y excluye solicitudes que terminaron después.

La consulta Power Query recorre next_cursor hasta agotar páginas con el mismo corte. Contar filas mide preguntas; sumar provider_calls mide rondas. Los tokens de entrada y salida se suman una sola vez por llamada.

Entrega de API	Uso
Swagger / OpenAPI	https://saldo-academico.onrender.com/docs
Cliente externo	docs/postman.json; login Bearer, servicios IA, historial y reportes. Credenciales introducidas de forma privada.
Persistencia	Cambios y consumo en Neon, independientes del disco efímero de Render.

09 Power BI y archivo exportable

El reporte académico mide consultas y tokens; los gráficos de ingresos y gastos no lo sustituyen.

Conexión HTTPS, actualización y contraste verificados

Web, API, Power BI y PBIX coinciden para noviembre de 2026 y usuario 2: nueve IDs únicos, 22 llamadas, 14.865 tokens de entrada y 2.630 de salida, total 17.495. El modelo se actualizó a las 04:58:22 Guatemala. La congelación API final de las 16:21:20 UTC volvió a comprobar exactamente la misma cohorte: no hubo nuevas solicitudes entre los cortes. Cada importación paginó con su propio as_of estable; no se afirma que ambos instantes sean idénticos. Filtros de servicio, fecha y período vacío comprobados; PBIX completo revalidado contra el corte final sin diferencias ni secretos conocidos.

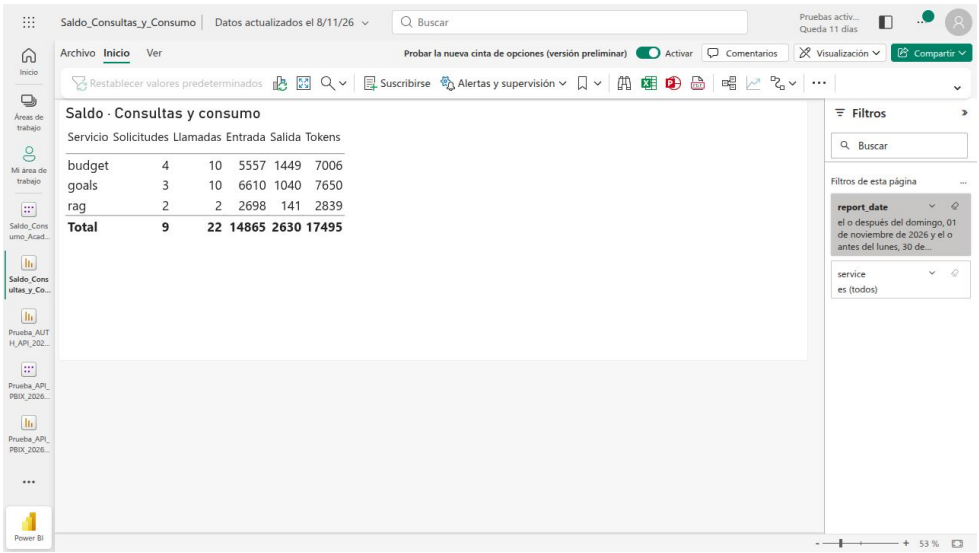


Figura 7. Power BI actualizado el 8/11: 9 solicitudes, 22 llamadas y 17.495 tokens, mismo alcance cloud que web/API.

Métrica contrastada	Valor
Solicitudes	9
Llamadas al proveedor	22
Tokens de entrada	14 865
Tokens de salida	2 630
Tokens totales	17 495

Corte as_of: 2026-11-08T16:21:20.915006+00:00

Actualización del modelo: 2026-11-08 04:58:22 America/Guatemala

Archivo entregado: Saldo_Consultas_y_Consumo.pbix. Informe y modelo importado. La contraseña se configura fuera de M. Un PBIX descargado es una copia fechada: no se renueva al refrescar la vista web.

Abrir informe en Power BI (cuenta institucional)

Power BI Desktop en Windows no se ejecutó. El análisis del PBIX usó un parser de terceros y no equivale a certificación Microsoft.

Las capas Free tienen cuotas y pausas; Microsoft mostraba 11 días de prueba en la inspección.

Ana cloud conserva la semilla financiera y 17.495/20.000 tokens; el escenario ampliado y cuota de 100.000 corresponden a local.

10 Reproducción y entrega

Código, SQL y pruebas permiten reconstruir el prototipo sin depender de una sesión de navegador.

Desde Ubuntu u otra máquina con Docker

Clonar el repositorio; copiar .env.example a .env y establecer contraseñas propias. Ejecutar el contenedor, seed, escenario local e indexación de guías y abrir localhost:8000. No se comparten secretos. El seed no imprime contraseñas ni reemplaza las de usuarios existentes.

```
docker compose up --build -d --wait
docker compose exec app python -m backend.seed
docker compose exec app python -m backend.demo
docker compose exec app python -m backend.knowledge
docker compose exec app pytest -q
```

Las pruebas usan una base temporal local. Para migraciones, alembic upgrade head; backend/schema.sql es una alternativa sobre una base vacía (ver docs/portabilidad.md). No aplicar ambas rutas sobre la misma base ni usar down --volumes para conservar registros.

El respaldo cloud original se restauró correctamente en PostgreSQL 18 en un contenedor separado, revisión de origen 0003 y base original preservada. Las migraciones posteriores y el SQL se comprobaron en arranque limpio. No se afirma haber restaurado una base financiera ampliada que aún no se ha sincronizado.

Power BI y continuidad desde Windows

El desarrollo, Docker, CI/CD y gestión cloud se realizaron desde Ubuntu. Power BI web completó el informe y su exportación. Si se necesita Desktop, Windows ya licenciado puede abrir el PBIX y consumir la misma API HTTPS con la cuenta BI; no es necesario trasladar el backend o Neon.

Criterios de la consigna	Artefacto o evidencia
A01 · propuesta/arquitectura	Este informe; docs/alcance.md, arquitectura.md y como-funciona.md.
A02-A03 · acceso y CRUD	Pruebas de roles/propiedad; GUI y endpoints administrativos/dominio.
A04-A06 · tres servicios IA	RAG con fuentes/memoria; agentes con herramientas externas.
A07-A08 · historial y cuotas	requests, provider_calls, tool_runs; reservas concurrentes.
A09-A10 · API y reporte web	Swagger, docs/postman.json, endpoints de reporte.
A11 · Power BI	Ver estado y evidencia en la sección Power BI; powerbi/consumo.pq y archivo PBIX.
A12-A14 · pruebas/cloud/CD	417 pruebas backend; Actions; Render; health SHA.
A15 · entregables	Repositorio, backend/schema.sql, backend/seed.py, PDF y PBIX.

Fuentes y referencias verificables

Consigna: Proyecto final - Programación Comercial.pdf, Recursos. Propuesta de producto original conservada en Recursos; alcance reducido aprobado en docs/alcance.md.

Banco Mundial · indicador FP.CPI.TOTL.ZG
Banguat · servicio de referencia de tipo de cambio
Swagger de la API publicada · Repositorio y configuración reproducible

Guía sencilla completa: docs/como-funciona.md. Recorrido de exposición: docs/guion-demostracion.md. Instalación y recuperación: README.md y docs/portabilidad.md. Operación posterior: revisar cuotas y fechas; retirar los accesos temporales al terminar. La entrega contiene datos ficticios y no incorpora secretos.

11 Recorrido de los datos

El mismo backend valida registros, calcula hechos, coordina la IA y entrega el reporte.

Del formulario al informe

React envía un registro autenticado; FastAPI valida propiedad, fecha y monto y PostgreSQL lo conserva. Al preguntar, la API recupera guías y hechos propios. Una consulta calculada responde sin modelo; una consulta abierta reserva cuota y usa Groq con herramientas permitidas. Respuesta, fuentes, pasos y tokens quedan en el historial. La API de reportes agrega ese consumo y Power BI importa una copia con corte estable.

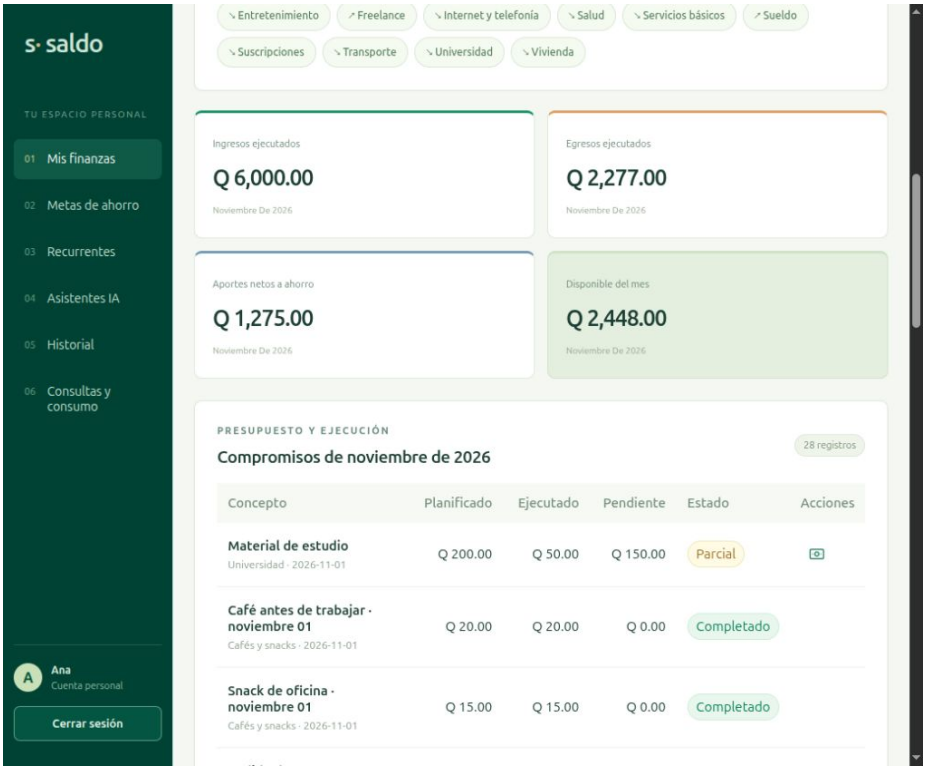


Figura 8. Escenario local ampliado de Ana: noviembre Q6.000 de ingresos, Q2.277 de pagos, Q1.275 de ahorro neto y Q2.448 de flujo. No es la base cloud ni el origen del Power BI publicado.

Dos instalaciones y un alcance explícito

El código puede ser el mismo en Ubuntu y Render, pero sus bases son independientes. Publicar no copia los registros locales. Cloud conserva la semilla financiera mientras la copia ampliada de Ana espera confirmación específica; su reporte Power BI sí incluye las consultas cloud contrastadas. El manual distingue preguntas y cifras de cada instalación.

Capa	Datos y acceso
Finanzas	Obligaciones, pagos, metas y movimientos propios. Cálculos Decimal; sin operaciones bancarias.
Asesor	Guía general versionada, recuperación textual y herramientas de lectura. Flujos externos específicos con instrucciones compactas.
Historial y BI	Solicitudes, herramientas y llamadas persistidas; API HTTPS paginada y cuenta BI de lectura.

12 Pruebas reales del asesor

Las cifras siguientes corresponden a ejecuciones concretas y no certifican todas las formulaciones posibles.

Servicio cloud	Llamadas	Tokens	Resultado observado
RAG	1	2256	Respuesta natural; fuentes y datos propios
Presupuesto	2	1731	Aritmética correcta; guarda de capacidad reforzada
Metas	2	2186	Cálculos correctos; afirmación de plazo corregida después

El presupuesto real confirmó flujo e inflación con dos inferencias (1.731 tokens); una frase que confundía margen con capacidad motivó una guarda contrastada offline con el texto real. Metas cloud confirmó aritmética pero exageró el plazo; tras corregir instrucciones, el ensayo local real usó dos inferencias y 2.693 tokens sin esa afirmación. No se gastó más Groq para volver a obtener una respuesta favorable ni se eliminaron intentos previos.

Fuentes externas y cálculos comprobados

Banco Mundial devolvió inflación anual Guatemala 2025 de 1,48841591086168 %. Banguat devolvió referencia 7,64243 GTQ/USD con fecha 8/11/2026. No se convirtieron en inflación mensual, rendimiento ni tasa bancaria garantizada.

En cloud la meta parte de Q500: seis aportes de Q500 producen Q3.500 y seis de Q750 producen Q5.000. En el ensayo local final parte de Q550: los mismos escenarios producen Q3.550 y Q5.050. La diferencia procede de bases distintas, no de un cambio de fórmula.

Qué protege la versión final

Las herramientas solo leen datos propios y hacen la aritmética. La guarda numérica contrasta importes y la barrera de capacidad evita presentar el flujo registrado como dinero libre para comprometer. Si falta calendario, mínimos o condiciones contractuales, se explican las ausencias. Una proyección no registra un pago ni demuestra asequibilidad.

Límites de la aceptación

El candidato real de presupuesto y el ensayo anterior de metas motivaron correcciones de redacción y regresiones con los textos archivados. El ensayo de metas con instrucciones finales se repitió con IA real en local; no se ocultaron ni descontaron los consumos anteriores. Las fuentes y pasos quedan disponibles en Historial.

Las pruebas automatizadas usan proveedores simulados; su éxito no promete disponibilidad externa permanente. La demostración debe revisar las cuotas y el entorno elegido antes de comenzar. La copia ampliada de Ana a la nube sigue separada y pendiente de confirmación.

Evidencia detallada privada: cierre-20261108; guía pública de reproducción y aceptación en docs/. No se publican contraseñas, claves ni respaldos.