PROYECTO FINAL / PROGRAMACIÓN COMERCIAL

Saldo

Finanzas personales asistidas por IA

Propuesta, arquitectura, modelo de datos y evidencias de implementación.

Objetivo y destinatarios

Ayudar a estudiantes y personas que registran manualmente sus finanzas a comparar presupuesto y ejecución, consultar sus registros con fuentes y explorar metas de ahorro mediante escenarios explicables.

El usuario administra sus propios registros e historial. El administrador gestiona usuarios, corpus, configuración de IA y cuotas. Una cuenta BI independiente solo consulta reportes.

Decisión de alcance	Implementación
Núcleo del producto	GTQ; categorías, obligaciones, pagos parciales, recurrentes mensuales y metas con aportes/retiros.
IA obligatoria	RAG sobre PostgreSQL + agente de presupuesto + agente de metas con herramientas y fuentes externas.
Reporterías	Consultas y tokens por usuario, fecha y servicio; misma API para web y Power BI.
Exclusiones aprobadas	Tarjetas, FIFO, intereses, préstamos, multidivisa operativa, banca real y fondos compartidos.
Presupuesto	USD 0; capas Free, sin tarjetas ni activaciones de pago.

Estado de esta revisión

Aplicación y API publicadas. 27 pruebas automatizadas aprobadas y CI/CD completo sobre el commit 0c5d2f7. Power BI verificado; el archivo PBIX forma parte de la entrega.

Corte técnico: 2 de noviembre de 2026. Fecha de entrega indicada en la consigna: 10 de noviembre. Todos los registros de demostración son ficticios.

Aplicación: https://saldo-academico.onrender.com
Repositorio: https://github.com/mariofrodm/saldo-academico

02 Arquitectura y stack

Un solo contenedor publica React y FastAPI en HTTPS. PostgreSQL conserva el estado; Render no requiere disco persistente.

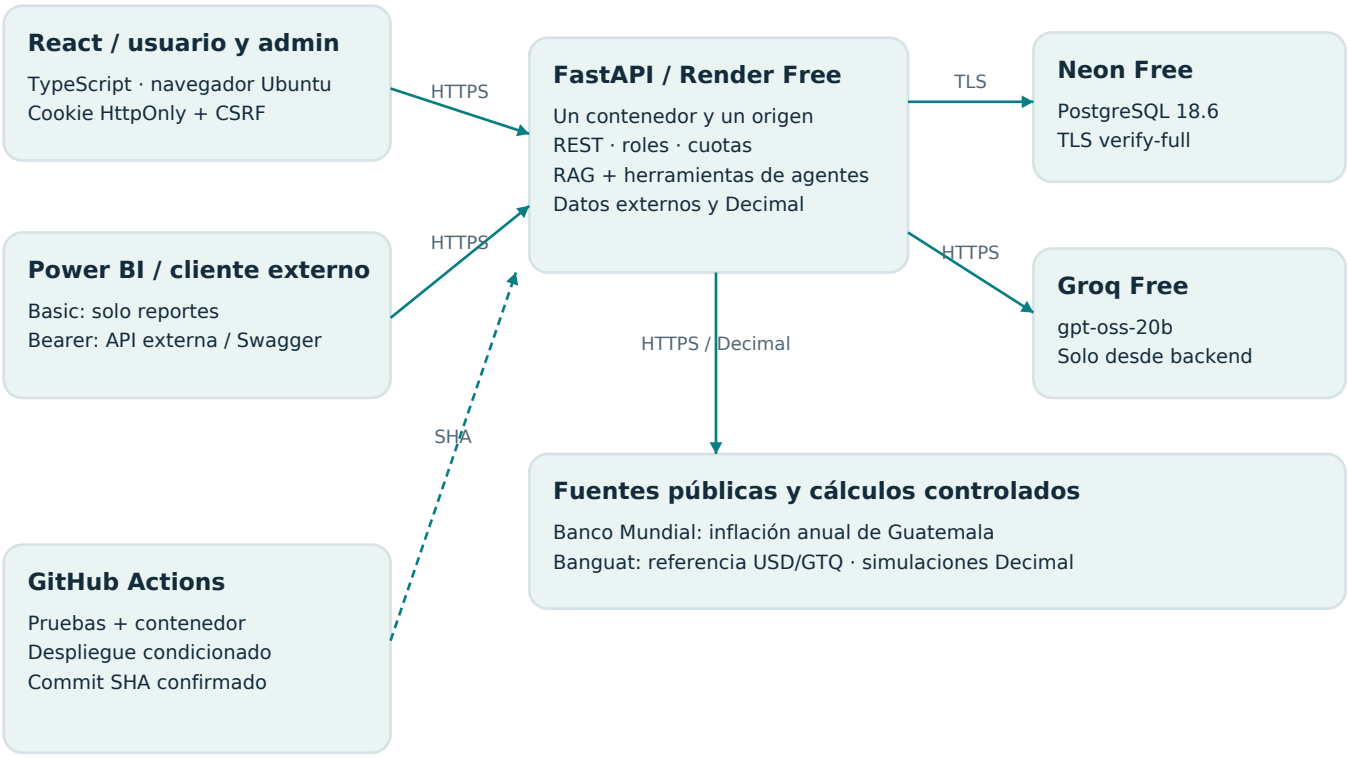


Figura 1. Recorrido real desde GUI, cliente externo y Power BI. Las claves de Groq y Neon permanecen en el servidor.

Componente	Tecnología y responsabilidad
Interfaz	React 19.3.1, TypeScript 7.0.2 y Vite 8.3.5; compilación estática.
API	Python 3.12, FastAPI 0.162.0, Pydantic, Uvicorn y psycopg 3.3.6; SQL parametrizado.
Persistencia	PostgreSQL 18.6 en Neon Free; PostgreSQL 17 en local/CI; migraciones Alembic.
Inferencia	Groq Free, openai/gpt-oss-20b; herramientas autorizadas y límites por ronda.
Publicación	Docker multietapa, usuario sin privilegios; Render Free 512 MB; GitHub Actions.
Analítica	Power BI web con importación HTTPS Basic; PBIX exportable y ruta Desktop si fuese necesaria.

Fabric no es una dependencia del backend. El RAG usa recuperación textual nativa de PostgreSQL; no requiere servicio vectorial ni embeddings de pago.

03 Servicios de IA y fuentes

El modelo decide herramientas y continúa con sus resultados. Los cálculos monetarios y las consultas autorizadas los ejecuta el backend.

RAG · respuesta sobre información recuperada

La pregunta recupera corpus activo mediante búsqueda textual española con índice GIN y movimientos propios relevantes. El contexto etiqueta documentos D* y movimientos M*. Se conserva la conversación y se incorporan los dos intercambios previos. La instrucción exige citar fuentes e indicar insuficiencia cuando los datos no permiten responder.

Ejemplo verificado: obligación Universidad Q900, pago Q400, pendiente Q500. La respuesta cita el movimiento M3; el acceso a movimientos de otra persona queda excluido antes de construir el contexto.

Agente presupuesto · combinación de información

financial_summary consulta ingresos, egresos y aportes netos por período. inflation consulta el indicador anual FP.CPI.TOTL.ZG de Guatemala en Banco Mundial. El agente elige las consultas y distingue el período de los movimientos del año de inflación disponible. Un año sin publicación produce una ausencia explícita de dato.

Agente metas · consulta y simulaciones

goal_snapshot recupera las metas propias; exchange_rate consulta la referencia USD/GTQ de Banguat; simulate_goal calcula escenarios con Decimal. Prueba cloud real: meta Q5,000, saldo Q500 y seis aportes de Q750 frente a seis de Q500. Proyecciones Q5,000 y Q3,500; cuatro herramientas y cinco llamadas al modelo.

Fuente	Dato y tratamiento
PostgreSQL / corpus	Registros propios y guía educativa administrada; identificadores recuperables en la respuesta.
Banco Mundial	Inflación anual de Guatemala. En el ensayo: 2025 = 1.48841591086168%; no se convierte a inflación mensual ni se confunde con 2026.
Banguat	Referencia del 02/11/2026: 7.64187 GTQ/USD en el ensayo; no es una tasa garantizada de liquidación bancaria.

Integración real en HTTPS

Servicio	Rondas	Tokens	Estado
RAG	1	583	success
Presupuesto	3	1926	success
Metas	5	3737	success

Ensayo cloud del 02/11/2026. Las consultas previas con información insuficiente también permanecen en historial y consumo; la tabla destaca una ejecución completa de cada servicio.

Control de ejecución

Herramientas en lista permitida por servicio, argumentos validados, tiempos máximos y hasta seis rondas. El límite sin respuesta final se registra como fallo con todo el consumo. Si una fuente falla no se sustituye silenciosamente por un valor inventado.

El contenido generado puede variar entre ejecuciones. Las fuentes y resultados de herramientas quedan persistidos para revisar sus afirmaciones; una respuesta natural no equivale por sí sola a una validación factual.

04 Modelo de datos · dominio

Esquema relacional real. Se muestran claves y atributos principales; backend/schema.sql contiene todas las columnas, restricciones e índices.

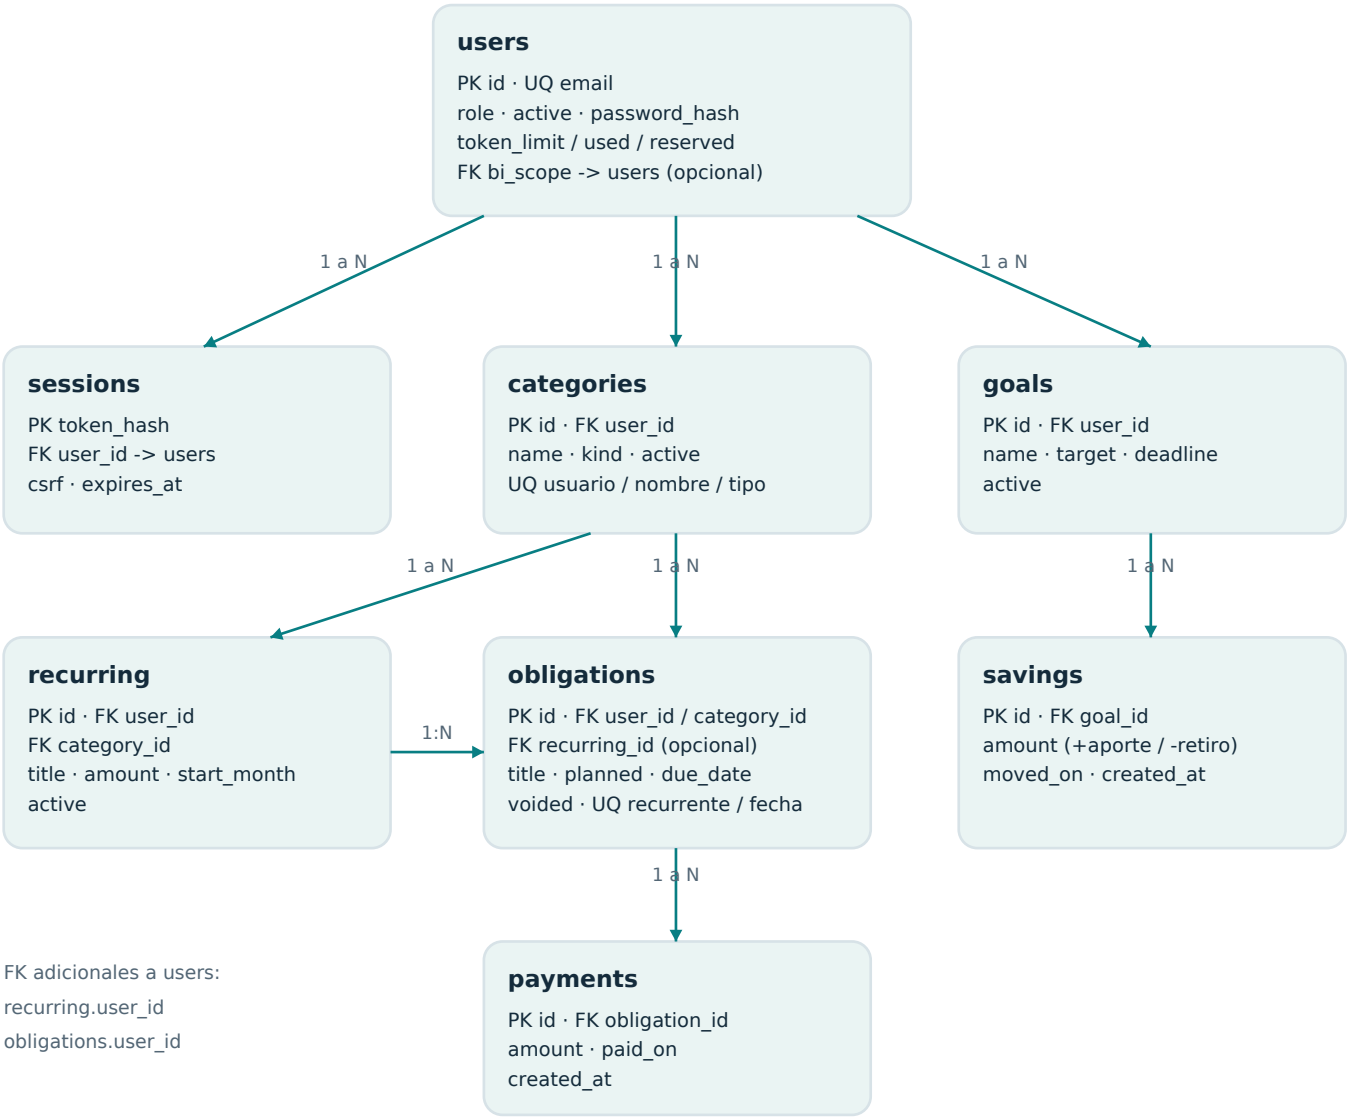
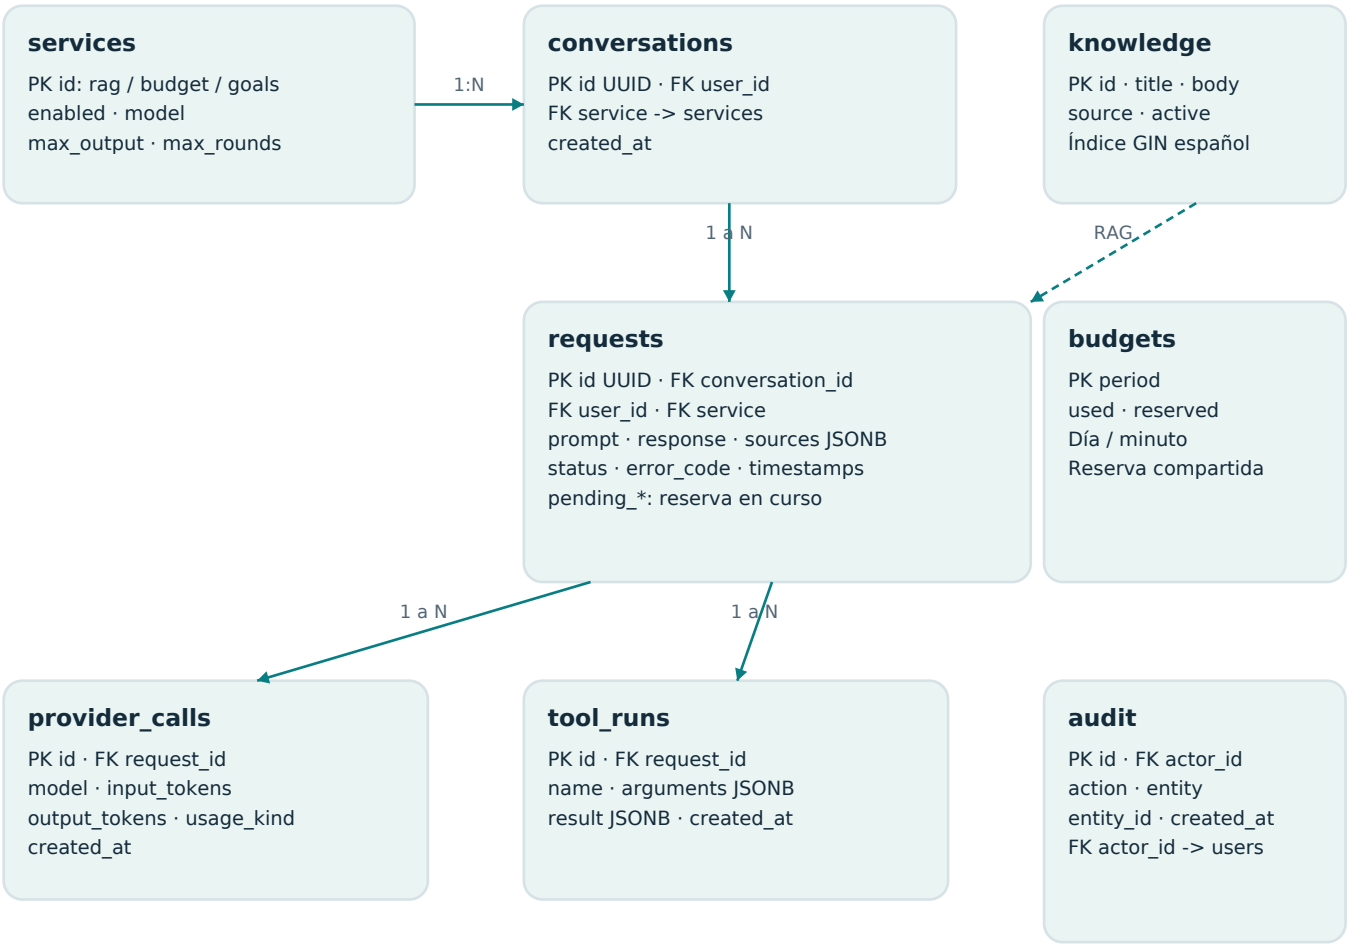


Figura 2. Ocho tablas de identidad y finanzas. PK: clave primaria; FK: clave foránea; UQ: unicidad. Las flechas indican la relación de padre a hijo.

Regla	Implementación
Exactitud monetaria	NUMERIC(15,2), Decimal y redondeo HALF_UP. Importes JSON como cadenas decimales.
Pagos e historial	Pagos separados de obligaciones. Se preservan monto y fecha de ejecución; anulación/inactivación en vez de borrar historial.
Recurrentes	UNIQUE(recurring_id,due_date) evita duplicar instancias; generación al solicitar el tablero, sin cron de pago.
Ahorro	Saldo = suma de movimientos. Los aportes reducen disponible y aumentan ahorro; no se presentan como consumo.

05 Modelo de datos · IA y auditoría

Las ocho tablas siguientes completan las 16 tablas del sistema. Conversaciones, rondas de proveedor y herramientas tienen granularidades distintas.



FK a users: conversations.user_id, requests.user_id y audit.actor_id.

requests.service también referencia services.id. knowledge y budgets no tienen FK.

Línea discontinua: recuperación lógica; no es una llave foránea.

Figura 3. Relaciones de IA, historial y control. Se conservan solicitudes fallidas y consumo desconocido estimado; no se elimina el historial para mejorar indicadores.

Entidad	Por qué existe
requests	Una pregunta del usuario: texto, respuesta, estado, fuentes y reserva pendiente.
provider_calls	Una ronda de inferencia: tokens de entrada/salida y origen del cómputo. Varias rondas pueden pertenecer a una solicitud.
tool_runs	Argumentos y resultado intermedio de cada herramienta, ligados a la pregunta.
budgets / audit	Reserva compartida por día/minuto y trazabilidad de cambios administrativos.

06 Acceso, cuotas y verificación

Los permisos se aplican en el backend y se prueban con accesos cruzados; ocultar una opción del menú no es el control de seguridad.

Acceso	Control aplicado
Usuario	Solo entidades, conversaciones y consumo propios; comprobación de propiedad también en herramientas.
Administrador	CRUD de usuarios/corpus y configuración de servicios; filtros globales por usuario, fecha y servicio.
Web y API externa	Contraseñas scrypt con sal; sesiones almacenadas como hash. Cookie HttpOnly, Secure en producción, SameSite Strict y CSRF; Bearer para clientes externos.
Power BI	Cuenta bi independiente; Basic solo sobre HTTPS y endpoints de lectura. Sin acceso a IA ni cambios del dominio.

Consumo verificable antes y después de la llamada

Cada ronda reserva de forma atómica cuota personal y compartida antes de contactar Groq. Después concilia los tokens informados. Un rechazo 4xx libera la reserva; si el uso no se confirma por un corte de conexión, se conserva una estimación conservadora y se etiqueta como tal.

Al arrancar se concilian reservas interrumpidas antiguas una sola vez. El límite configurado no constituye una promesa de disponibilidad de Groq: también aplican las cuotas del proveedor y las del proyecto.

Verificación automatizada	Cobertura significativa
Identidad y dominio	Login/CSRF, roles, propiedad, pagos parciales, arrastre sin duplicados, recurrentes y ahorro sin sobregiro.
RAG y agentes	Fuentes y memoria, insuficiencia, varias herramientas/rondas, conversaciones ajenas y límite de pasos.
Cuotas y errores	Reservas concurrentes, reversión compartida, 429, timeout, usage ausente y recuperación idempotente.
Reporte y API	Cursor, fecha Guatemala, snapshot as_of, Basic de lectura, health y OpenAPI.

27 pruebas aprobadas contra PostgreSQL 17 aislado. La suite simula Groq y las fuentes públicas: no consume tokens. Se complementó con llamadas reales, limitadas, a los tres servicios y con integración HTTPS/Neon.

Alcance de la evidencia: no se realizó una auditoría de seguridad ni una prueba de carga masiva. La suite muestra el comportamiento esperado de los casos cubiertos.

07 Despliegue y costo cero

La publicación usa los planes gratuitos existentes. No se agregaron tarjetas, discos ni servicios de pago.

Pruebas → contenedor → despliegue por SHA

El workflow ejecuta backend y construcción/arranque del contenedor en jobs separados. Deploy requiere éxito de ambos, push a main y habilitación explícita. Render tiene auto-deploy apagado; GitHub solicita el commit exacto mediante ref=SHA y espera disponibilidad con ese mismo SHA y base accesible.

Commit acreditado: 0c5d2f7b0df16b643fc070056fd57563e0b2bedf.

Ejecución CI/CD completa en GitHub Actions

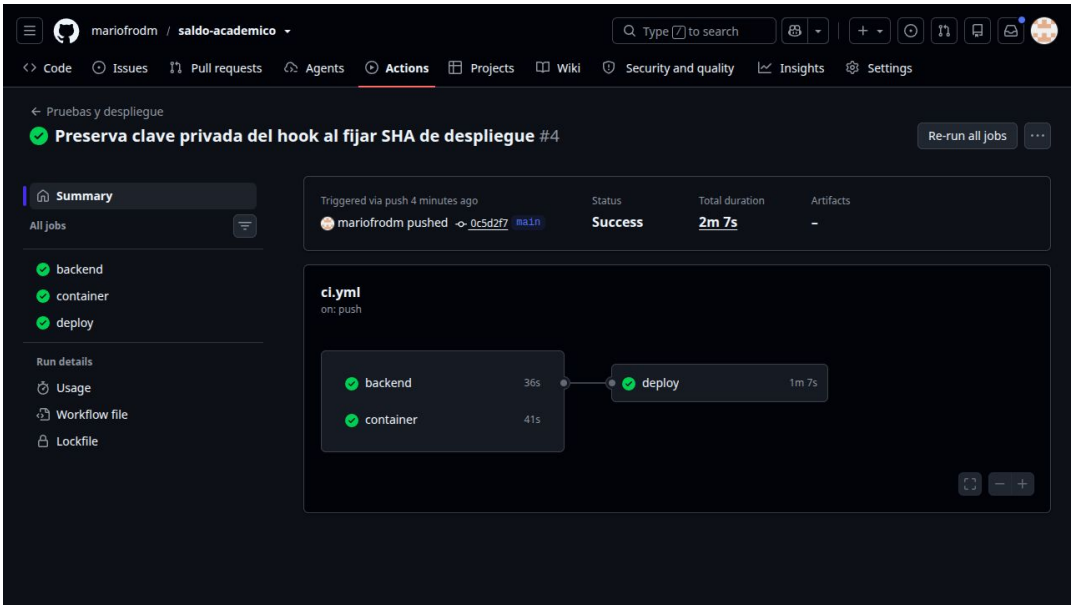


Figura 4. Evidencia de pruebas y despliegue satisfactorios en la misma ejecución.

Servicio / plan	Condición de operación
Render Free	Contenedor 512 MB. Puede dormir tras inactividad; abrir antes de la demostración. No usar pings artificiales para evitar la suspensión.
Neon Free	Persistencia PostgreSQL y suspensión por inactividad; cuota finita. TLS verify-full en conexión directa y agrupada.
Groq Free	Cuotas por minuto/día y clave con vencimiento 02/12/2026. No habilitar planes facturables al alcanzar límites.
GitHub / Power BI	Repositorio público y Actions para el proyecto. Cuenta institucional para Power BI; revisar vencimiento y conservar PBIX exportado.

La infraestructura Free puede cambiar o suspenderse; el proyecto no depende de comprar una ampliación. Si una cuota se agota, se reduce el uso o se espera su reinicio. Las credenciales quedan fuera de Git y del PDF.

08 Aplicación publicada y API

La captura corresponde a la aplicación real en Render y usa datos ficticios persistidos en Neon.

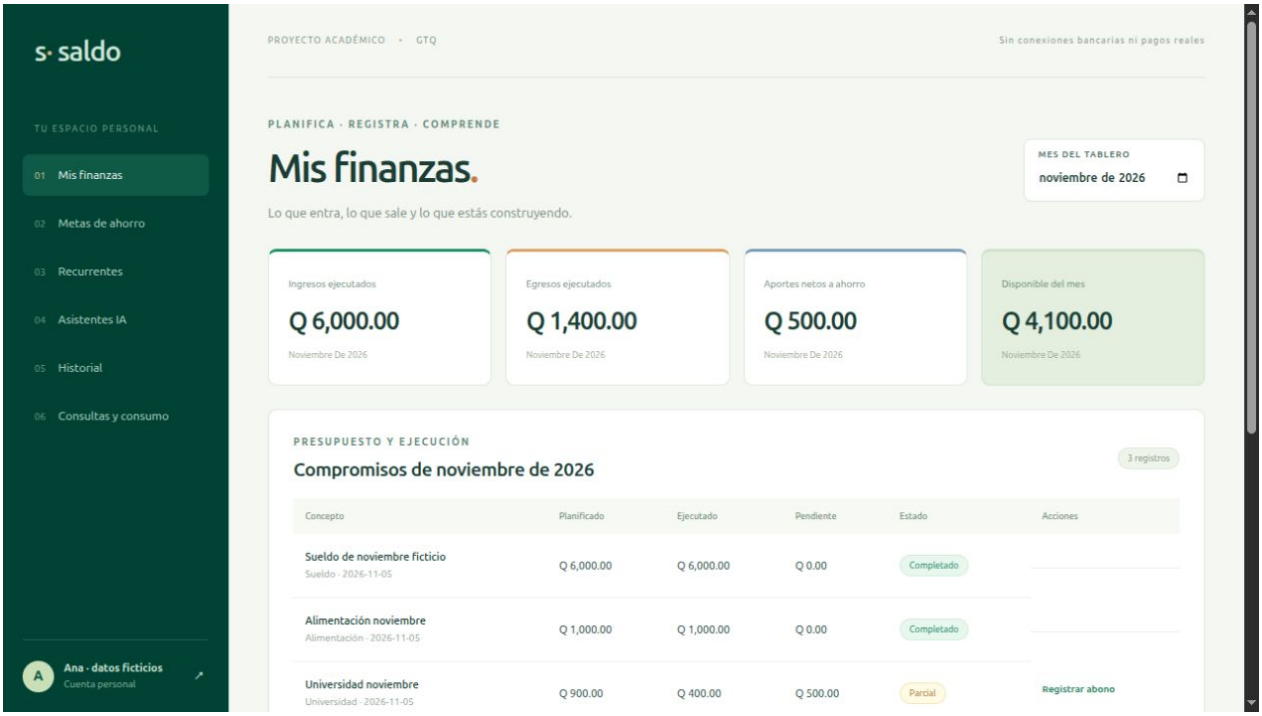


Figura 5. GUI de Saldo publicada por HTTPS. El usuario consulta finanzas y accede a metas, asistentes, historial y consumo.

Consulta y consumo: mismas reglas en web y Power BI

GET /api/v1/reports/usage entrega una fila por solicitud y agrega todas sus llamadas. GET /api/v1/reports/summary resume por servicio. Filtros de fecha en America/Guatemala, usuario según permisos y servicio. Un único as_of congela el corte y excluye solicitudes que terminaron después.

La consulta Power Query recorre next_cursor hasta agotar páginas con el mismo corte. Contar filas mide preguntas; sumar provider_calls mide rondas. Los tokens de entrada y salida se suman una sola vez por llamada.

Entrega de API	Uso
Swagger / OpenAPI	https://saldo-academico.onrender.com/docs
Cliente externo	docs/postman.json; login Bearer, servicios IA, historial y reportes. Credenciales introducidas de forma privada.
Persistencia	Cambios y consumo en Neon, independientes del disco efímero de Render.

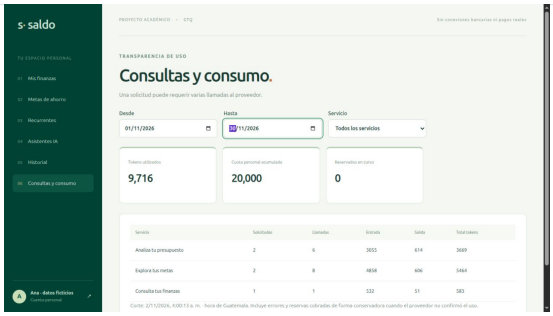


Figura 6. Reporte web de consultas y tokens utilizado en el contraste con Power BI.

09 Power BI y archivo exportable

El reporte académico mide consultas y tokens; los gráficos de ingresos y gastos no lo sustituyen.

Conexión HTTPS, actualización y contraste verificados

Web, API y PBIX coinciden para noviembre de 2026: cinco solicitudes terminadas y ninguna consulta nueva durante el contraste. Filtro presupuesto: 2 solicitudes, 6 llamadas y 3.669 tokens. Actualización a petición del modelo completada el 02/11/2026 a las 09:51:24 (Guatemala), sin gateway local. PBIX decodificado desde Ubuntu: modelo y consulta HTTPS paginada presentes; cero secretos detectados.

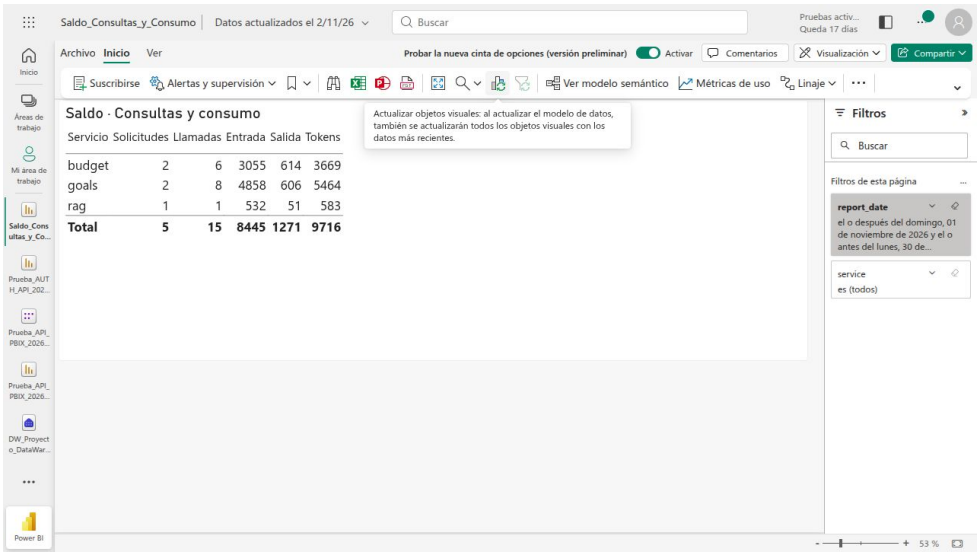


Figura 7. Informe definitivo de consultas y consumo conectado a la API de Saldo.

Métrica contrastada	Valor
Solicitudes	5
Llamadas al proveedor	15
Tokens de entrada	8 445
Tokens de salida	1 271
Tokens totales	9 716

Archivo entregado: Saldo_Consultas_y_Consumo.pbix. Exportación del informe y modelo; las credenciales se gestionan en el servicio, no se escriben en el código M.

Abrir informe en Power BI (cuenta institucional)

10 Reproducción y entrega

Código, SQL y pruebas permiten reconstruir el prototipo sin depender de una sesión de navegador.

Desde Ubuntu u otra máquina con Docker

Clonar el repositorio; copiar .env.example a .env y establecer claves propias. Ejecutar el contenedor, cargar datos ficticios y abrir localhost:8000. El seed no imprime contraseñas ni reemplaza las de usuarios existentes.

```
docker compose up --build -d --wait
docker compose exec app python -m backend.seed
docker compose exec app pytest -q
```

Las pruebas usan una base temporal local. Para migraciones, alembic upgrade head; backend/schema.sql es una alternativa sobre una base vacía (ver docs/portabilidad.md). No aplicar ambas rutas sobre la misma base ni usar down --volumes para conservar registros.

Respaldo verificado: PostgreSQL 17.11 en Linux, restauración en base nueva, 16 tablas más alembic_version, 19 FK validadas, 57 restricciones y revisión 0003 coincidentes. Se preservó la base original. Este ensayo no acredita restaurar PostgreSQL 18 en 17; el dump privado no se publica.

Power BI y continuidad desde Windows

El desarrollo, Docker, CI/CD y gestión cloud se realizaron desde Ubuntu. Power BI web completó el informe y su exportación. Si se necesita Desktop, Windows ya licenciado puede abrir el PBIX y consumir la misma API HTTPS con la cuenta BI; no es necesario trasladar el backend o Neon.

Power BI Desktop no se ejecutó en Windows.

Power BI/Fabric muestra 17 días de prueba; revisar antes del vencimiento.

Las capas Free tienen cuotas y pausas por inactividad.

Criterios de la consigna	Artefacto o evidencia
A01 · propuesta/arquitectura	Este informe, pp. 1-3; docs/alcance.md y arquitectura.md.
A02-A03 · acceso y CRUD	Pruebas de roles/propiedad; GUI y endpoints administrativos/dominio.
A04-A06 · tres servicios IA	RAG con fuentes/memoria; agentes con herramientas externas; p. 3.
A07-A08 · historial y cuotas	requests, provider_calls, tool_runs; reservas concurrentes; pp. 5-6.
A09-A10 · API y reporte web	Swagger, docs/postman.json, endpoints de reporte; p. 8.
A11 · Power BI	Ver estado y evidencia en p. 9; powerbi/consumo.pq y archivo PBIX.
A12-A14 · pruebas/cloud/CD	27 pruebas; Actions; Render; health SHA; pp. 6-7.
A15 · entregables	Repositorio, backend/schema.sql, backend/seed.py, PDF y PBIX.

Fuentes y referencias verificables

Consigna: Proyecto final - Programación Comercial.pdf, Recursos. Propuesta de producto original conservada en Recursos; alcance reducido aprobado en docs/alcance.md.

Banco Mundial · indicador FP.CPI.TOTL.ZG
Banguat · servicio de referencia de tipo de cambio
Swagger de la API publicada · Repositorio y configuración reproducible

Operación posterior: revisar cuotas y fechas; retirar la clave SSH limitada al repositorio y revocar la clave Groq al terminar. La entrega contiene datos ficticios y no incorpora secretos operativos.